



Projekat II

Analitika velikih mobilnih tokova podataka

Mihajlo Madić 2119

Big Data Systems

Jun 2026, Niš

Izgraditi i uporediti dva pipeline-a za stream analitiku nad velikim SUMO skupom podataka o gradskom saobraćaju:

- Apache Spark Structured Streaming
- Apache Flink

Zajednički tok obrade:

SUMO → Kafka → Stream analitika → Kafka → Consumer / mapa

- Trendovi zagađenja u blizini značajnih prostornih entiteta
- Intenzitet saobraćaja u blizini ulica, zona ili objekata
- Tumbling i sliding prozori kao runtime parametri
- Uporedivi rezultati iz Spark i Flink implementacije

Ciljna arhitektura

Izvori

SUMO FCD izlaz, SUMO emission izlaz, referentni entiteti iz OSM / Google Maps izvora

Transport

File-to-Kafka producer i Kafka topic-i za sirove i obrađene tokove

Obrada

Spark Structured Streaming i Flink implementacije nad ekvivalentnim ulazima

Prikaz

Kafka consumer sa map-oriented prikazom rezultata

Planirane faze

- 1 Bootstrap, arhitektura i setup odluke
- 2 SUMO generisanje podataka i definicija šema
- 3 Kafka i kontejnerska infrastruktura
- 4 Implementacija producer-a
- 5 Spark analitika
- 6 Flink analitika
- 7 Consumer i vizualizacija
- 8 Benchmarking i finalna prezentacija

Toulouse, France

Grad je fiksiran za SUMO scenario, OSM referentne entitete i primere downstream analitike.

- Dovoljno veliki urbani i prigradski saobraćajni tokovi
- Aerodrom, glavna železnička stanica, gradski centar, stadion i bolnica
- Prstenasti putevi i centralni koridori pogodni za merenje intenziteta saobraćaja

- Snapshot: `data/reference/toulouse_spatial_entities.geojson`
- POI/zone: airport, Matabiau, Capitole, Stadium, Purpan
- Koridori: Périphérique Extérieur, Périphérique Intérieur, Route de Narbonne, Boulevard de Strasbourg
- Geometrije entiteta: poligoni za zone, Point za Matabiau i MultiLineString za koridore
- Svaki entitet ima stabilan ID, OSM reference i prag za matching

Tip	Pravilo poklapanja
radius	tačka vozila unutar zadatog radijusa
area_buffer	unutar poligona ili buffer zone
corridor	udaljenost od OSM linijskog koridora


- 9 entiteta u početnom snapshot-u
- 4 poligona, 4 MultiLineString koridora, 1 tačka
- Isti entity_id, OSM reference i pragovi za Spark i Flink
- Distance se računaju metarski, ne preko sirovih stepeni

Kafka ugovori događaja

Topic	Sadržaj	Ključ	Potrošači
<code>mobility.fcd</code>	položaj, brzina, lane, vreme	<code>vehicle_id</code>	traffic jobs
<code>mobility.emissions</code>	CO2, NOx, PMx, fuel, noise	<code>vehicle_id</code>	pollution jobs
<code>analytics.traffic</code>	agregati po entitetu i prozoru	<code>engine/entity/window</code>	mapa/report
<code>analytics.pollution</code>	emisije po entitetu i prozoru	<code>engine/entity/window</code>	mapa/report

- JSON vrednosti, `schema_version=1`, ISO 8601 event-time
- Runtime argumenti prozora isti za Spark i Flink: tip, veličina, slide, watermark

Početna Docker topologija



Režimi: full, spark-only, flink-only; bez persistent Docker volume-a.

- Grad izabran: Toulouse, France
- Početni spatial reference snapshot dokumentovan sa OSM geometrijama
- SUMO odluka: lokalna one-shot skripta, bez kontejnerizacije za sada
- Kafka topic-i, event schema i početna Docker topologija implementirani
- Ekvivalentna spatial matching semantika u Spark i Flink aplikacijama
- Compose režimi: `full`, `spark-only`, `flink-only`
- Checkpoint: `automation/phase1_docker_topology.sh`